パッケージを配ろう

Atsushi Odagiri

2024-04-25

Outline

お前誰よ

- Atsushi Odagiri
- Open Collector
- Python は 1.5 くらいのころから

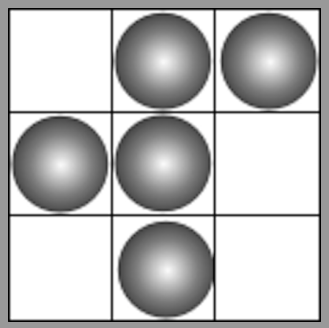

Open Collector

ケンオール

パッケージエコシステム

- 作る
  - setuptools, poetry-core, hatchling...
- 配る
  - pypi
- 使う
  - pip, poetry, hatch...

パッケージを配るということ

- 広く一般に向けて配る
- 狭い範囲で限られた利用のために配る

広く一般に向けて pypi で配る

- PyPA ツールのデフォルト
- `tween` でアップロード
- `pip` がダウンロードしてインストール

狭い範囲で限られた利用のために配る

- マイクロサービスのそれぞれて使うようなライブラリ
- 特殊なパッチをあてたローカルフレーバーライブラリ

狭い範囲で配る

- 社内ネットワークや VPN の中で
- k8s や vpc の中で
- 範囲内の IP アドレスにだけ
- 認証をつけたい

httplib.server でのお手軽 repository

- ダウンロードできるリンクがあればいいので `http` モジュールでサーバーを起動するだけ
- wheel ファイルのあるディレクトリで実行

```
python3 -m pip download pyramid
python3 -m http.server
```

Directory listing for /

- hupper-1.12.1-py3-none-any.whl
- PasteDeploy-3.1.0-py3-none-any.whl
- plaster-1.1.2-py2.py3-none-any.whl
- plaster_pastedeploy-1.0.1-py2.py3-none-any.whl
- pyramid-2.0.2-py3-none-any.whl
- setuptools-69.5.1-py3-none-any.whl
- translationstring-1.4-py2.py3-none-any.whl
- venusian-3.1.0-py3-none-any.whl
- WebOb-1.8.7-py2.py3-none-any.whl
- zope.deprecation-5.0-py3-none-any.whl
- zope.interface-6.3-cp311-cp311-manylinux_2_5_x86_64.manylinux1_x86_64.manylinux_2_17_x86_64.manylinux2014_x86_64.whl

URL 指定でインストール

- pip は URL 指定で直接インストールできる
- 正確なファイル名を知らないといけない
- wheel はプラットフォームなどの情報を含んでいる

```
pip install \
    http://localhost:8000/pyramid-2.0.2-py3-none-any.whl
```

複雑な wheel ファイル名

- oh…

```
zope.interface-6.4
-cp311
-cp311
-manylinux_2_5_x86_64.manylinux1_x86_64.manylinux_2_17_x86_64.
.whl
```

find-links

- `find-links` で指定した場所から探しだしてもらう

```
pip install -f http://localhost:8000 zope.interface
```

no-index

- 場合によっては pypi への接続も制限される環境
- 全てをお手軽 repository から取得するなら `no-index` も使うようにしてみよう
- `no-index` pypi などの index を見にいかない
- `find-url` 指定したページからダウンロード URL をスクレーピング

index は必要？

- pip を直接使うなら `find-url` でもいいかも？
- メタデータを取得するのに配布物をダウンロードするという効率の悪さはある
- `poetry source add` で使えるのは simple repository
  - pip だと `--index-url` で指定するものに相当

独自の pypi を立てたい!

- PyPI 自体のソースコードは公開されている
  - `https://github.com/pypi/warehouse`
  - インフラ構築保守など手間もかかる
- devpi
  - `https://github.com/devpi/devpi`
  - PyPI へのプロキシやプロジェクトごとの名前空間設定など多機能
  - それなりにインフラ構築保守の手間がかかる
- `http.server` くらいに簡単に立ち上って欲しいところ

パッケージを配るための PEP

- PEP 458 – Secure PyPI downloads with signed repository metadata
- PEP 480 – Surviving a Compromise of PyPI: End-to-end signing of packages
- PEP 503 – Simple Repository API
- PEP 592 – Adding “Yank” Support to the Simple API
- PEP 629 – Versioning PyPI’s Simple API
- PEP 658 – Serve Distribution Metadata in the Simple Repository API
- PEP 691 – JSON-based Simple API for Python Package Indexes
- PEP 700 – Additional Fields for the Simple API for Package Indexes
- PEP 714 – Rename dist-info-metadata in the Simple API

Simple Repository

representation

- HTML PEP503
- JSON PEP691

バージョン

- 1.0 PEP503/PEP691
- 1.1 PEP700
- PEP714 メタデータフィールドの取り扱いについての修正
  - warehouse の実装で間違えがあったらしい

PyPI の Simple Repository

- `https://pypi.org/simple/` とても大きいのでアクセス注意！

実装方針

- 標準ライブラリでいこう
  - Batteries Included!
- 1 ファイルデプロイ
- DB などを使わず起動するだけで使える

project list

- ホストしているプロジェクト (ほぼパッケージの意味) を一覧で出すだけ
- v1.0 のプロジェクトに関する情報は `name` のみ

使うライブラリ

- これだけ!
- 100% 標準ライブラリのみ!

```
import argparse
import hashlib
import itertools
import json
import operator
import pathlib
import re
import zipfile
from typing import TypedDict, NotRequired, Iterable
from wsgiref.types import WSGIApplication, WSGIEnvironment, St
from wsgiref.simple_server import make_server
```

Meta

- simple repository に関する情報
- バージョン

```
Meta = TypedDict(
    "Meta",
    {
        "api-version": str,
    },
)
```

project detail

- プロジェクト (パッケージ) ごとのダウンロード可能なファイル一覧
- ファイルの URL やパッケージメタデータなど

project file の typing

- 事前に確認可能なパッケージメタデータ
- ダウンロードに必要な情報 URL やハッシュ

```
ProjectFile = TypedDict(
    "ProjectFile",
    {
        "filename": str,
        "url": str,
        "hashes": dict[str, str],
        "requires-python": NotRequired[str],
        "dist-info-metadata": NotRequired[str],
        "core-metadata": NotRequired[str],
        "gpg-sig": NotRequired[bool],
        "yanked": NotRequired[bool],
    },
)
```

project detail の typing

- project file の一覧が主な情報

```
ProjectDetail = TypedDict(
    "ProjectDetail",
    {
        "name": str,
        "files": list[ProjectFile],
        "meta": Meta,
    },
)
```

project list の typing

```
Project = TypedDict("Project", {"name": str})
ProjectList = TypedDict(
    "ProjectList",
    {
        "meta": Meta,
        "projects": list[Project],
    },
)
```

wheel ファイルを探しだす

- pathlib でできちゃうね!

```
wheelhouse.glob("*.whl")
```

wheel ファイル名から情報を取得

- wheel ファイルのファイル名は形式が決まっている
  - PEP 491 The Wheel Binary Package Format 1.9
  - `{distribution}-{version}(-{build tag})?-{python tag}-{abi tag}-{platform tag}.whl.`

wheel ファイル名から情報を取得

- 今回欲しいのは `distiribution`
- `"-"` で `split` して最初の 1 つ

```
def extract_dist_name(wh: pathlib.Path) -> str:
    return wh.name.split("-", 1)[0]
```

プロジェクト名を正規化

- PEP 503 で正式に正規化方法が定義されている
- アルファベットは全て小文字
- 記号は - に正規化
- 例: `zope.interface` -> `zope-interface`

```
def normalize(name: str) -> str:
    return re.sub(r"[-_.]+", "-", name).lower()
```

metadata

- METADATA を wheel から取り出す
- wheel は zip ファイル
- METADATA の場所は決まっている
  - PEP 491 The Wheel Binary Package Format 1.9
  - `{distribution}-{version}.dist-info/` contains metadata.

```
def get_metadata(whl: pathlib.Path):
    parts = whl.name.split("-")
    dist_name, version = parts[0], parts[1]
    metadata_path = f"{dist_name}-{version}.dist-info/METADATA
    with zipfile.ZipFile(whl) as zf:
        with zf.open(metadata_path) as metadata:
            return metadata.read()
```

全部まとめて wheel ファイルの情報を取得

- プロジェクト名をキーにしてメタデータと wheel ファイルパスをグルーピング

```
def load_wheels(
    wheelhouse: pathlib.Path,
) -> Iterable[tuple[str, Iterable[tuple[str, bytes, pathlib.Pa
    wheels = itertools.groupby(
        (
            (normalize(extract_dist_name(w)), get_metadata(w)
            for w in wheelhouse.glob("*.whl")
        ),
        key=operator.itemgetter(0),
    )
    return wheels
```

プロジェクトごとにファイル情報をまとめる

- プロジェクト名、メタデータ、wheel ファイルパスをもとに JSON データを作成

```
project = ProjectDetail(
    {"name": project_name, "files": [], "meta": meta})
project_details[project_name] = project
for _, metadata, p in files:
    hash = hashlib.sha256(p.read_bytes()).hexdigest()
    f = ProjectFile(
        {
            "filename": p.name,
            "url": f"/{project_name}/files/{p.name}",
            "hashes": {
                "sha256": hash,
            },
            "dist-info-metadata": metadata.decode("utf-8"),
            "core-metadata": metadata.decode("utf-8"),
        }
```

wsgi アプリケーション:project list

```
class ProjectListApp:
    def __init__(self, project_list: ProjectList) -> None:
        self.project_list = project_list

    def __call__(
        self, environ: WSGIEnvironment, start_response: StartR
    ) -> Iterable[bytes]:
        start_response(
            "200 OK", [("Content-Type", "application/vnd.pypi.
        )
        return [json.dumps(self.project_list).encode("utf-8")]
```

wsgi アプリケーション:project detail

```
class ProjectDetailApp:
    def __init__(self, project_details: dict[str, ProjectDetai
        self.project_details = project_details

    def __call__(
        self, environ: WSGIEnvironment, start_response: StartR
    ) -> Iterable[bytes]:
        project_name = environ["wsgiorg.routing_args"][1]["pro
        if project_name not in self.project_details:
            return not_found(environ, start_response)
        start_response(
            "200 OK", [("Content-Type", "application/vnd.pypi.
        )
        return [json.dumps(self.project_details[project_name])
8")]
```

wsgi アプリケーション: ダウンロード

- wheel ファイルの中身をレスポンスボディにする
- wheel の content-type は特に決まってないので application/octet-stream にする
- ブラウザでアクセスしたときにダウンロードになるよう Content-Disposition をつける

```
class WheelDownloadApp:
    def __init__(self, wheelhouse: pathlib.Path) -> None:
        self.wheelhouse = wheelhouse

    def __call__(
        self, environ: WSGIEnvironment, start_response: StartR
    ) -> Iterable[bytes]:
        file_name: str = environ["wsgiorg.routing_args"][1]["w
        p = self.wheelhouse / file_name
        if not p.exists():
            return not_found(environ, start_response)
        start_response(
```

WSGI アプリケーションのルーティング

- / project list
- /{project}/ project detail
- 実際に wheel ファイルをダウンロードする URL
  - 今回は /{project}/files/{wheel} にします
  - メタデータを /{project}/files/{wheel}.metadata にします

```
r"^/$"

r"^/(?P<project_name>[^/]+)/$"

r"^/(?P<project_name>[^/]+)/files/(?P<wheel_file_name>[^/]+\.w

r"^/(?P<project_name>[^/]+)/files/(?P<wheel_file_name>[^/]+\.w
```

さあ!wsgi アプリケーションを立ち上げよう!

- 重要なのは wheel ファイルを置いてある `wheelhouse` ディレクトリ
- `host`, `port` は web アプリケーションとして必要な情報

```
def main() -> None:
    parser = argparse.ArgumentParser()
    parser.add_argument("wheelhouse", type=pathlib.Path)
    parser.add_argument("--host", type=str, default="0.0.0.0")
    parser.add_argument("--port", type=int, default=8000)
    args = parser.parse_args()
    app = make_app(args.wheelhouse)
    httpd = make_server(args.host, args.port, app)
    httpd.serve_forever()


if __name__ == "__main__":
    main()
```

まとめ

- パッケージの配布方法
  - 広く一般に配布するなら pypi
  - 狭い範囲で限られた利用のために配る
    - http.server + find-links
    - simple repository + index-url
- simple repository は PEP で定義されている
  - 配布する分には意外と簡単
  - 標準ライブラリだけでも実装可能

参考文献

- PyPA Simple Repository API, https://packaging.python.org/en/latest/specifications/simple-repository-api/
- The Python Package Index, https://github.com/pypi/warehouse
- Welcome to Warehouse's documentation!, https://warehouse.pypa.io/